

مسئله چیست؟

فرض کنید یک سند اداری یا فنی ۱۵۰ صفحه‌ای دارید و می‌خواهید بدانید «فلان شماره چند رقم است؟» یا «انواع فلان مورد کدام‌اند؟». راه معمول، ورق زدن و جست‌وجوی دستی است که هم زمان‌بر است و هم پرخطا. ابزارهای هوش مصنوعی اینترنتی (مانند ChatGPT) هم برای اسناد محرمانه مناسب نیستند، چون متن سند باید به سرورهای خارجی ارسال شود.

ChatBot این مشکل را حل می‌کند: کاربر سند خود (PDF, Word) یا متن ساده را در یک پوشه می‌گذارد، به زبان فارسی — حتی محاوره‌ای — سؤال می‌پرسد و سامانه پاسخ را همراه با ذکر صفحه‌ی منبع و درصد اطمینان ارائه می‌دهد. همه‌چیز روی کامپیوتر شخصی اجرا می‌شود و هیچ داده‌ای از دستگاه خارج نمی‌شود.

سامانه چگونه کار می‌کند؟ (به زبان ساده)

روش به‌کاررفته در ادبیات هوش مصنوعی «تولید پاسخ به کمک بازیابی» (RAG) نام دارد و مانند کار یک کتابدار دقیق است:

- 1 **خواندن سند:** متن از فایل PDF یا Word استخراج می‌شود؛ جدول‌ها نیز جداگانه خوانده و به جمله‌های قابل فهم تبدیل می‌شوند.
- 2 **تکه‌تکه کردن:** متن به قطعه‌های کوچک هم‌پوشان تقسیم می‌شود — مانند فیش‌برداری از یک کتاب.
- 3 **اثر انگشت معنایی:** برای هر قطعه، با یک شبکه‌ی عصبی، یک «اثر انگشت عددی» ساخته می‌شود که معنای آن قطعه را نمایش می‌دهد؛ به این ترتیب قطعه‌هایی که درباره‌ی یک موضوع‌اند، اثر انگشت مشابهی دارند.
- 4 **جست‌وجوی دومرحله‌ای:** وقتی کاربر سؤال می‌پرسد، ابتدا قطعه‌های مشابه سؤال با ترکیب جست‌وجوی معنایی و کلیدواژه‌ای پیدا می‌شوند؛ سپس یک مدل داور دقیق‌تر (بازچین یا Reranker) سؤال را با تکتک نامزدها مقایسه می‌کند و بهترین‌ها را برمی‌گزیند.
- 5 **نگارش پاسخ:** یک مدل زبانی که به‌طور محلی روی همان کامپیوتر اجرا می‌شود، فقط بر اساس قطعه‌های انتخاب‌شده، پاسخی روان به فارسی می‌نویسد.
- 6 **ارائه‌ی مستند:** پاسخ همراه با نام فایل، شماره‌ی صفحه‌ی منبع و درصد اطمینان نمایش داده می‌شود تا قابل راستی‌آزمایی باشد.

چه چیزهایی این پروژه را متمایز می‌کند؟

۱) **فارسی محوری:** متن‌های فارسی استخراج‌شده از PDF اغلب به‌هم‌ریخته‌اند؛ سامانه نویسه‌های عربی/فارسی را یکسان‌سازی می‌کند، پرسش‌های محاوره‌ای («چی»، «کدوم») را به شکل رسمی بازنویسی می‌کند و حتی جهت متن وارونه‌ی جدول‌ها را اصلاح می‌کند. ۲) **حریم خصوصی کامل:** پس از یک‌بار دانلود مدل‌ها، سامانه کاملاً آفلاین کار می‌کند. ۳) **صداقت علمی:** اگر پاسخ در سند نباشد، به جای حدس زدن، صریحاً می‌گوید «در سند پیدا نشد».

سنجش کیفیت: ادعا با عدد

برای آنکه کیفیت سامانه قابل اندازه‌گیری باشد (نه صرفاً چند مثال نمایشی)، یک **آزمون استاندارد داخلی** طراحی شده است: ۱۶ پرسش با پاسخ مشخص از یک سند فنی واقعی ۱۴۳ صفحه‌ای (دستورالعمل صورتحساب الکترونیکی سازمان مالیاتی) تهیه شد و یک برنامه‌ی ارزیاب، پاسخ سامانه به هر پرسش را به‌طور خودکار تصحیح می‌کند. نتایج:

آزمایش	نتیجه	معنی
پیدا کردن پاسخ در سند — بدون مدل داور	۴۴٪	جست‌وجوی معنایی ساده، به‌تنهایی کافی نیست
پیدا کردن پاسخ در سند — با مدل داور (بازچین)	۸۱٪	افزودن مرحله‌ی داوری، دقت بازبایی را تقریباً دو برابر کرد
صحت پاسخ نهایی نوشته‌شده	۳۸٪	گلوگاه فعلی، توان مدل زبانی کوچک محلی در نگارش است

این آزمون علاوه بر اندازه‌گیری، نقش «نگهبان» را هم دارد: پس از هر تغییر در سامانه، دوباره اجرا می‌شود تا مطمئن شویم چیزی خراب نشده است — رویکردی که در مهندسی نرم‌افزار حرفه‌ای مرسوم است. تحلیل همین اعداد نشان داد مسیر بهبود آینده، به‌کارگیری مدل زبانی بزرگ‌تر است؛ زیرا در ۸۱٪ موارد پاسخ درست در اختیار مدل قرار می‌گیرد.

امکانات نرم‌افزار

سامانه سه شکل استفاده دارد: **گفت‌وگوی تعاملی** در خط فرمان (پاسخ‌ها کلمه‌به‌کلمه و زنده نمایش داده می‌شوند)، **پرسش تکی** برای استفاده‌ی سریع، و یک **وب‌سرویس (REST API)** که به برنامه‌های دیگر — مثلاً یک سایت یا اپلیکیشن موبایل — اجازه می‌دهد از طریق شبکه سؤال بفرستند و پاسخ بگیرند. نصب نیز خودکار است: با یک دستور، همه‌ی پیش‌نیازها نصب و سند نمونه ایندکس می‌شود. پروژه دارای ۳۶ آزمون خودکار، مستندات دوزبانه و امکان اجرا در Docker است.

فناوری‌های به‌کاررفته

فناوری	نقش در پروژه (به زبان ساده)
زبان Python	زبان اصلی پیاده‌سازی کل سامانه
FAISS (محصول Meta)	بایگانی سریع «اثر انگشت‌های عددی» و جست‌وجو میان آن‌ها در کسری از ثانیه
multilingual-e5	شبکه‌ی عصبی سازنده‌ی اثر انگشت معنایی؛ چندزبانه با پشتیبانی خوب فارسی
bge-reranker-v2	مدل داور که مرتبط‌ترین قطعه‌های سند را با دقت بالا برمی‌گزیند
Qwen 2.5 (فشرده‌شده)	مدل زبانی نویسنده‌ی پاسخ؛ به‌صورت بهینه روی پردازنده‌ی معمولی اجرا می‌شود
FastAPI	چارچوب ساخت وب‌سرویس برای اتصال برنامه‌های دیگر به سامانه

جمع‌بندی

ChatBot نشان می‌دهد که می‌توان یک دستیار پرسش‌وپاسخ اسناد را با تمرکز بر زبان فارسی، بدون وابستگی به سرویس‌های ابری خارجی و با سخت‌افزار معمولی ساخت. وجه تمایز اصلی پروژه، رویکرد مهندسی آن است: هر تصمیم فنی — از انتخاب مدل داور تا تنظیم پارامترها — با آزمون استاندارد و عدد پشتیبانی شده است، و معماری چندلایه‌ی آن (بازبایی، داوری، نگارش) امکان بهبود هر بخش را به‌طور مستقل فراهم می‌کند.

نمودار معماری سامانه

کارکرد سامانه دو مرحله دارد: آماده‌سازی که فقط یک‌بار (یا پس از تغییر اسناد) انجام می‌شود، و پاسخ‌گویی که برای هر سؤال تکرار می‌شود. کادرهای پررنگ، ورودی/خروجی کاربر و کادرهای آبی روشن، مدل‌های هوش مصنوعی هستند.



تمام اجزای این نمودار روی یک کامپیوتر شخصی و بدون اتصال به اینترنت اجرا می‌شوند

ورودی/خروجی کاربر (محل) مدل هوش مصنوعی (محل) پردازش متنی